



PROYECTO UNIDAD 2

Antonio Aldama

Alejandro Herrera

Jesús Retana

Juan David Zuñiga

METODOLOGÍA

Objetivo: predecir el precio de los automóviles utilizando el algoritmo Random Forest Regressor.

Variables

- Variable objetivo (Y):
 - price
- Variables predictoras (X):
 - Se probaron distintas combinaciones de variables como:
 - engine-size
 - horsepower
 - curb-weight
 - city-mpg
 - wheel-base
 - bore
 - highway-L/100km

Parámetros evaluados

- n_estimators: entre 50 y 300 árboles.
- max_depth: entre 4 y 12 niveles.
- min_samples_leaf: de 1 a 5.
- min_samples_split: de 2 a 4.
- random_state para reproducibilidad.

Proceso

1. División de datos:

- 80% entrenamiento.
- 20% prueba.

2. Entrenamiento de 30 configuraciones diferentes de Random Forest.

3. Evaluación mediante:

- R^2 (coeficiente de determinación).
- RMSE (raíz del error cuadrático medio).

RESULTADOS

COMPARACIÓN DE LOS MEJORES MODELOS

Modelo	R ² Train	R ² Test	RMSE
23	9.435	9.506	245.942
26	9.311	9.366	278.566
15	9.047	9.321	288.128

COMPARACIÓN DE LOS PEORES MODELOS

Modelo	R ² Train	R ² Test	RMSE
17	9.108	5.035	779.416
12	8.299	5.933	705.357
7	9.499	7.654	535.739

- EL MEJOR DESEMPEÑO FUE OBTENIDO POR EL MODELO 23.
- EL PEOR DESEMPEÑO FUE OBTENIDO POR EL MODELO 17.
- LOS MODELOS QUE INCLUYERON VARIABLES COMO HORSEPOWER, ENGINE-SIZE Y CURB-WEIGHT LOGRARON MEJORES RESULTADOS.

INTERPRETACIÓN




¿Qué significa que el desempeño en prueba sea mejor que en entrenamiento?

Como ocurrió en el Modelo 23:

- R^2 Train = 0.9435
- R^2 Test = 0.9506

Esto indica que el modelo generaliza correctamente y no está memorizando los datos de entrenamiento. La diferencia puede deberse a que el conjunto de prueba resultó ligeramente más sencillo de predecir.



¿Qué significa cuando entrenamiento es mucho mejor que prueba?

Ejemplo: Modelo 17

- R^2 Train = 0.9108
- R^2 Test = 0.5035

El modelo aprendió demasiado los datos de entrenamiento pero falló con datos nuevos. Esto es un caso de sobreajuste (overfitting).

Indicadores generales

- R^2 alto y similar en entrenamiento y prueba:
 - Buen modelo.
- R^2 entrenamiento muy superior al de prueba:
 - Sobreajuste.
- Ambos R^2 bajos:
 - Subajuste.



REFLEXIÓN

Interpretación de métricas

¿Por qué un modelo con menor R^2 puede ser más confiable? Un R^2 muy alto no siempre significa que el modelo sea mejor. Si el rendimiento es excelente en entrenamiento pero disminuye en prueba, puede existir sobreajuste, es decir, el modelo aprendió demasiado los datos de entrenamiento y tendrá dificultades para predecir datos nuevos. Un modelo con un R^2 ligeramente menor pero estable en ambos conjuntos suele ser más confiable.

¿Qué indica un RMSE más alto? El RMSE mide el error promedio de las predicciones. Un valor más alto significa que las predicciones están más alejadas de los valores reales, por lo que el modelo tiene menor precisión. En general, se prefieren modelos con RMSE más bajo.

¿Cómo identificar sobreajuste o subajuste?

- Sobreajuste (Overfitting): R^2 de entrenamiento muy alto y R^2 de prueba considerablemente más bajo.
- Subajuste (Underfitting): R^2 bajos tanto en entrenamiento como en prueba, lo que indica que el modelo no captura adecuadamente los patrones de los datos.

Impacto de las variables

¿Qué ocurriría al agregar más variables? Incorporar variables relevantes como marca, año o tipo de combustible podría mejorar la capacidad predictiva del modelo, ya que aportan información adicional relacionada con el precio del vehículo.

Variables más importantes: Las variables con mayor influencia fueron engine-size y horsepower, ya que reflejan características directamente relacionadas con el desempeño y valor comercial del automóvil.

Efecto de agregar o quitar variables

- Agregar variables relevantes ayudó a mejorar las predicciones y reducir el error (RMSE).
- Eliminar variables importantes disminuyó el desempeño del modelo.
- Incluir demasiadas variables poco relacionadas con el precio puede introducir ruido y reducir la capacidad de generalización.

¿Qué parámetros pueden mejorar el desempeño?

- `max_depth`: controla la profundidad del árbol para evitar el sobreajuste.
- `min_samples_leaf`: aumenta el número mínimo de muestras por hoja, haciendo el modelo más estable.
- `max_features`: limita las variables evaluadas en cada división, reduciendo la varianza y mejorando la generalización.

¿Cómo elegir un algoritmo de regresión?

- Regresión Lineal: adecuada cuando existe una relación simple y lineal entre las variables.
- Random Forest: recomendada para relaciones complejas y no lineales, ofreciendo buen rendimiento con poco ajuste.
- XGBoost o LightGBM: ideales para grandes volúmenes de datos y cuando se busca la máxima precisión predictiva.

Modelos simples vs. modelos complejos

Modelo simple

- Fácil de interpretar y explicar.
- Menor riesgo de sobreajuste.
- Menor costo computacional.
- Puede no capturar relaciones complejas entre variables.

Modelo complejo

- Mayor capacidad predictiva.
- Detecta patrones no lineales e interacciones complejas.
- Más difícil de interpretar.
- Mayor riesgo de sobreajuste y mayor consumo de recursos.

Impacto de aumentar el tamaño del dataset

- Mejora la capacidad de generalización del modelo.
- Reduce la influencia del ruido y de los valores atípicos.
- Permite entrenar modelos más complejos con menor riesgo de sobreajuste.
- Produce evaluaciones más confiables en el conjunto de prueba.

Aplicaciones en otros contextos

- Predicción de ventas: estimar la demanda futura utilizando historial de ventas, promociones y estacionalidad.
- Predicción de costos médicos: estimar gastos o primas de seguros a partir de características del paciente.
- Predicción de precios: bienes raíces, vehículos o productos de comercio electrónico.
- Análisis financiero: estimación de ingresos, costos y riesgos empresariales.



Aprendizajes sobre Random Forest

- Random Forest logró predecir el precio de vehículos con alta precisión.
- La selección de variables tuvo un impacto mayor que aumentar el número de árboles.
- Variables mecánicas como:
 - engine-size
 - horsepower
 - curb-weight
- fueron las más relevantes para estimar el precio.

Comparación entre modelos

- El mejor modelo fue el 23, con:
 - $R^2 = 0.9506$
 - RMSE = 2459.42
- Los peores modelos utilizaron variables menos relacionadas con el precio, obteniendo R^2 menores a 0.60.

CONCLUSIÓN

Random Forest demostró ser un algoritmo robusto para problemas de regresión, ya que captura relaciones no lineales entre variables y mantiene un alto nivel de precisión cuando se seleccionan adecuadamente las características predictoras.

Nuestro mejor modelo alcanzó un R^2 de 95.06%, lo que significa que explicó aproximadamente el 95% de la variabilidad del precio de los automóviles, mostrando que Random Forest es una técnica muy eficiente para este tipo de problemas predictivos.



GRACIAS